

ANÁLISIS DE DATOS CASO SUBASTA SUGANORTE



JEFFERSON BALCAZAR
CARLOS ARTURO AGUDELO
MILTON VANEGAS DELGADO

INSTITUTO DE EDUCACIÓN TÉCNICA PROFESIONAL – INTEP
UNIDAD DE SISTEMAS Y ELECTRICIDAD
ROLDANILLO VALLE

2026

ANÁLISIS DE DATOS CASO SUBASTA SUGANORTE

JEFFERSON BALCAZAR
CARLOS ARTURO AGUDELO
MILTON VANEGAS DELGADO

Trabajo de grado presentado como requisito para optar al título de Especialista en Big Data
y Análisis de Datos

Asesor
JUAN URIEL CASTAÑO VERA
Magister

INSTITUTO DE EDUCACIÓN TÉCNICA PROFESIONAL – INTEP
UNIDAD DE SISTEMAS Y ELECTRICIDAD
ROLDANILLO VALLE

2026

Contenido

	Pág.
1. Resumen	6
2. Abstract	9
3. Introducción.....	10
4. Pregunta de Investigación	12
5. Justificación.....	13
6. Objetivos	15
6.1. Objetivo General	15
6.1.1 Objetivos Específicos.....	15
7. Marco Teórico	16
7.1. Big Data.....	16
7.2. Las 5V del Big Data	16
7.2.1 Volumen:.....	16
7.2.2 Velocidad:	17
7.2.3 Variedad:	17
7.2.4 Veracidad:	17
7.2.5 Valor:	17
7.3. Metodología ASUM-DM	17
7.4. Modelado Predictivo de Precios (Regresión).....	19
7.5. Clasificación y Probabilidad de Venta (Árboles de Decisión).....	19
7.6. Segmentación Estratégica (K-Means Clustering)	19
7.6.1 Método del Codo (Elbow):	21
7.6.2 Coeficiente de Silueta:	21
7.7. Pronóstico de Series Temporales (Holt-Winters).....	21
7.8. Estado del Arte	22
7.9. Marco Contextual	25
7.10. Marco Normativo	26
8. Desarrollo Técnico y Análisis de resultados	27
8.1. Análisis Exploratorio de Datos (EDA).....	27

8.2.	Evolución del Modelado de Precios: Regresión Lineal vs. Múltiple	28
8.3.	Clasificación y Dinámica de Venta (Árbol de Decisión)	32
8.4.	Perfiles de Compradores: Segmentación K-Means: A través del algoritmo K- Means, se identificaron tres perfiles con comportamientos financieros y operativos opuestos:	33
8.5.	Pronóstico con Holt-Winters	36
8.6.	Random Forest y XGBoost como Alternativa a la Regresión Lineal	38
8.7.	Detección de Transacciones Anómalas — Isolation Forest	39
9.	Aspectos Bioéticos	40
9.1.	Aplicación de los principios rectores de la investigación	40
9.2.	Protección, normatividad y entorno socioambiental	41
9.3.	Mitigación de impactos negativos y custodia de la información	41
10.	Conclusiones	43
11.	Bibliografía	45

Lista de Figuras

Figura 1 Ecuación Regresión Lineal Múltiple	19
Figura 2 Regresión Lineal Simple. Peso Vs Precio	28
Figura 3 Regresión Lineal Múltiple. Procedencia, sexo, hora llegada	29
Figura 4 Estructura del Árbol de Decisión para la clasificación de lotes. El diagrama presenta los nodos de decisión donde se identifican la Categoría y el Peso como las variables determinantes para predecir la agilidad de la puja. Los nodos finales (hojas)	32
Figura 5 Visualización de clústeres de compradores. El color rojo representa el segmento "Destete Precoz Premium", el azul al "Mercado de Frigorífico" y el verde al "Destete Numeroso y Homogéneo"	33
Figura 6 Método del Codo (inercia) y Coeficiente de Silueta para la selección de K. La línea punteada señala K=3, la decisión estratégica adoptada.	34
Figura 7 Pronóstico de tendencia de precios mediante suavizamiento exponencial triple (Holt-Winters). La proyección permite anticipar ciclos estacionales en la subasta.	36

1. Resumen

El presente estudio aborda las deficiencias identificadas en la distribución y reporte semanal de precios del ganado comercializado en la Subasta Suganorte, ubicada en Zarzal (Valle del Cauca). Estas deficiencias se caracterizan por una clasificación manual e inconsistente de los lotes, así como por la dependencia de la media aritmética como principal indicador de precios, la cual es altamente sensible a valores atípicos (outliers). Esta situación genera distorsiones en la representación del valor real del mercado, dificultando la toma de decisiones comerciales y estratégicas por parte de compradores y proveedores. El análisis se realizó sobre un dataset consolidado de aproximadamente nueve meses de subastas (junio 2025 – marzo 2026), con un total de 11.253 registros transaccionales.

El objetivo general del proyecto consistió en desarrollar un sistema de analítica descriptiva y prescriptiva que permita la clasificación objetiva de los lotes, la predicción de precios, la detección anticipada de tendencias del mercado y la segmentación estratégica de compradores, generando información accionable para el fortalecimiento de estrategias comerciales y de marketing.

Siguiendo la metodología IBM Corporation, 2015 ASUM-DM, se implementaron medidas estadísticas robustas, modelos de regresión lineal simple y múltiple, pronóstico de series temporales (Holt-Winters), clasificación mediante Árbol de Decisión y segmentación de compradores mediante K-Means.

Al tratarse de un proyecto aplicado a una empresa real se nos hacía necesario tener una visión de escalabilidad y viabilidad a futuro, aunque los modelos predictivos y de clasificación se desarrollaron como una prueba de concepto con fines académicos, esta metodología nos permitió estructurar una fase inicial del despliegue del Notebook para el reporte

de precios. Con esto la empresa cuenta con una base tecnológica para que un futuro integre algún modelo predictivo en su operación.

Entre los principales resultados se destacan:

- El desarrollo de modelos de regresión lineal simple y múltiple para la predicción del precio por kilogramo, alcanzando un R^2 del 29% al incorporar variables como procedencia, hora de entrada y categoría del animal. Esto significa que este modelo puede explicar hasta un 29% de la varianza o fluctuación de los precios del ganado, el 71% restante obedece a factores que no están presentes en el software que la empresa usa para el ingreso y facturación de los animales, como por ejemplo raza, edad, preñeces, entre otros.
- La implementación de un modelo de series temporales Holt-Winters sobre datos semanales (junio 2025 – marzo 2026), con pronóstico de 8 semanas que evidencia una tendencia alcista moderada en el precio por kilogramo, proyectando valores alrededor de \$8.600 para mayo-junio 2026.
- La construcción de un Árbol de Decisión para predecir el interés de los compradores en los lotes (clasificación: hubo puja vs. salió en base), identificando umbrales clave: animales con precio base inferior a \$8.275 y peso hasta 181,5 kg presentan mayor probabilidad de puja, mientras que precios base superiores a \$10.100 en lotes livianos reducen significativamente el interés del comprador.
- La segmentación de compradores mediante K-Means (K=3 perfiles estratégicos): Perfil 0 – “Destete Precoz Premium”, Perfil 1 – “Mercado de Frigorífico” y Perfil 2 – “Destete Numeroso y Homogéneo” constituye la base para diseñar listas de difusión diferenciadas en WhatsApp y estrategias de marketing dirigidas.

En conclusión, la transición desde métricas volátiles hacia indicadores estadísticos robustos, junto con la implementación de modelos predictivos y de segmentación basados en datos, permite obtener una visión más estable, objetiva y accionable del mercado ganadero. Se recomienda adoptar la mediana como principal indicador de referencia en los reportes de precios, aprovechar el pronóstico Holt-Winters para anticipar tendencias, utilizar el árbol de decisión como guía operativa para el martillo durante la subasta, y emplear los perfiles K-Means para diseñar estrategias de comunicación y marketing diferenciadas por tipo de comprador.

2. Abstract

The present study evolves from a descriptive analysis toward a predictive and prescriptive analytics framework applied to the Suganorte Auction (Zarzal, Valle). Given that approximately 90% of transactions are based on price per kilogram, an ecosystem of Machine Learning models was implemented to mitigate market uncertainty. Linear Regression models were developed for price estimation, Decision Trees to predict the probability of bidding on specific lots, and K-Means Clustering for strategic buyer segmentation. Finally, the Holt- Winters method was incorporated for trend forecasting, enabling management to transition from reactive decision-making to a data-driven strategy.

The results demonstrate that while the livestock market is influenced by external variables not currently captured (such as pregnancy or biotype), the predictive models provide a realistic and grounded baseline for the "martillo" (auctioneer) to optimize operational times.

Furthermore, the identification of three distinct buyer profiles (Destete Precoz Premium, Mercado de Frigorífico, and Destete Numeroso y Homogéneo) allows the company to shift from mass marketing via WhatsApp to personalized strategies. This analytical approach not only improves auction efficiency but also establishes a robust statistical foundation for future strategic growth and competitive advantage in the region.

Keywords: Predictive Analytics, Machine Learning, Livestock Auction, K-Means Clustering, Holt-Winters, Data-Driven Decision Making.

3. Introducción

El sector ganadero en Colombia representa uno de los pilares fundamentales de la economía rural, siendo las subastas comerciales el escenario principal donde se dinamiza la compra y venta de semovientes. En este contexto, la Subasta Suganorte, ubicada en Zarzal (Valle del Cauca), se destaca como un referente regional. Sin embargo, la comercialización de ganado enfrenta un reto constante: la alta volatilidad de los precios y la incertidumbre en el comportamiento de los compradores, factores que dificultan la planeación estratégica y la agilidad en las operaciones de venta.

Actualmente, aproximadamente el 90% de las transacciones en Suganorte se realizan bajo la modalidad de subasta por kilo. Esta dependencia directa del peso y la categoría del animal convierte la fijación de precios en una tarea compleja para el martillo, quien debe equilibrar las expectativas del vendedor con la realidad del mercado en tiempo real.

Históricamente, esta labor se ha apoyado en la intuición y el conocimiento empírico; no obstante, ante el volumen creciente de datos y la necesidad de modernización, surge la oportunidad de integrar herramientas de analítica avanzada para profesionalizar este proceso.

En respuesta a este contexto, el presente proyecto implementa un ecosistema de analítica predictiva mediante la metodología ASUM-DM, integrando modelos de Regresión, Árboles de Decisión, Clustering y Series Temporales. Este análisis se plantea desde un enfoque honesto y aterrizado a la realidad del mercado, reconociendo que, si bien existen variables externas no capturadas actualmente (como el biotipo, la preñez o la edad exacta), el uso de datos históricos de los últimos 9 meses permite establecer patrones confiables. El objetivo es transformar la intuición del martillo en decisiones respaldadas por evidencia estadística, optimizando la agilidad

operativa y permitiendo una segmentación de clientes que revolucione las actuales estrategias de marketing de la empresa. Se selecciona este marco de trabajo ya que abarca el ciclo de vida de una solución de datos con un fuerte enfoque en el despliegue operativo y la viabilidad del negocio. Al aplicarse en una empresa real, ASUM-DM nos permite no solo el desarrollo académico de los algoritmos como prueba de concepto, sino también la ejecución de una fase inicial de despliegue de un Notebook en Jupiter, trazando la ruta para futuras integraciones.

Finalmente, este trabajo no solo busca resolver un problema técnico de estimación de precios, sino que pretende sentar las bases para una cultura de datos en Suganorte. Al demostrar el impacto positivo de la analítica en la agilidad del martillo y en la efectividad de las listas de difusión de WhatsApp, se propone una hoja de ruta donde la información se convierte en el activo más valioso para garantizar la competitividad y la transparencia en el mercado ganadero del norte del Valle.

4. Pregunta de Investigación

¿Cómo puede la implementación de un ecosistema de analítica predictiva —basado en modelos de regresión lineal, clasificación mediante árbol de decisión, segmentación K-Means y pronóstico de series temporales Holt-Winters— optimizar la fijación de precios por kilogramo, anticipar el interés de los compradores en cada lote y permitir una segmentación estratégica de clientes en la Subasta Suganorte (Zarzal, Valle del Cauca), a partir del análisis de los registros transaccionales del período junio 2025 – marzo 2026?

5. Justificación

La importancia de este proyecto radica en la necesidad de modernizar la toma de decisiones en la Subasta Suganorte S.A., transitando de un modelo basado en la experiencia empírica hacia uno respaldado por la ciencia de datos. En un mercado donde el 90% de las transacciones se definen por el precio por kilogramo, reducir la incertidumbre no es solo una ventaja competitiva, sino una necesidad operativa. Por lo tanto, la inversión de tiempo, esfuerzo investigativo y recursos tecnológicos se justifica plenamente al transformar un entorno de alta volatilidad en una operación eficiente, medible y rentable. La implementación de analítica predictiva se fundamenta en los siguientes pilares:

En primer lugar, por su conveniencia y optimización operativa. Históricamente, la fijación de precios base ha dependido de la intuición del subastador. Al proporcionar un modelo de Regresión y un Árbol de Decisión, el proyecto entrega una base técnica para establecer rangos de precios más acertados. Esto permite identificar de antemano la probabilidad de puja de los lotes, agilizando la dinámica de la subasta y ahorrando tiempos críticos en la pista de venta, lo que se traduce en una operación significativamente más eficiente.

En segundo lugar, por su impacto en la evolución del marketing y su trascendencia para la comunidad. Actualmente, la comunicación con los clientes se realiza de forma genérica. La segmentación mediante Clustering (K-Means) permite que la empresa identifique perfiles claros (como el buscador de Genética Premium, el Mercado Frigorífico o el Ganadero de Levante). Con esta información, Suganorte puede implementar estrategias dirigidas, enviando a cada cliente la oferta que realmente se ajusta a su comportamiento. Más allá del beneficio corporativo, este ecosistema trasciende a la comunidad ganadera local (proveedores y productores del norte del Valle); al estandarizar los precios mediante datos objetivos, se fomenta un mercado agropecuario

más transparente y equitativo, reduciendo las fricciones por tasaciones subjetivas y fortaleciendo la confianza del campesino en la subasta.

En tercer lugar, por su articulación con las políticas y planes de desarrollo territorial. El desarrollo de este ecosistema analítico se alinea directamente con las políticas nacionales impulsadas por el Ministerio de Agricultura y Desarrollo Rural y el Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC), específicamente en el marco de la estrategia "Agro 4.0" y la transformación digital agropecuaria. A nivel regional, el proyecto responde a las apuestas de competitividad e innovación tecnológica del Plan de Desarrollo del Valle del Cauca, al introducir herramientas de la Cuarta Revolución Industrial (Big Data y Machine Learning) en un eslabón tradicional de la economía rural, promoviendo el desarrollo de un campo inteligente.

En síntesis, este proyecto justifica la creación de una ventaja competitiva basada en datos. El uso de la metodología ASUM-DM garantiza que el análisis sea estructurado y escalable. Aunque el modelo reconoce la influencia de variables externas, su enfoque aterrizado a la realidad proporciona una brújula estratégica que antes no existía. Este trabajo no solo resuelve problemas inmediatos de precios, sino que establece la hoja de ruta técnica para que Suganorte lidere la innovación tecnológica en el sector ganadero regional, transformando la información en su activo más valioso.

6. Objetivos

6.1. Objetivo General

Implementar un ecosistema de analítica predictiva y prescriptiva que, mediante el uso de Machine Learning, permita optimizar la fijación de precios, agilizar la dinámica del martillo y realizar una segmentación estratégica de clientes en la subasta ganadera Suganorte S.A. de Zarzal (Valle del Cauca).

6.1.1 Objetivos Específicos

- Desarrollar un modelo de predicción de precios mediante regresión lineal múltiple para estimar el valor por kilogramo de los lotes, consolidando una herramienta de tasación basada en variables físicas y operativas.
- Pronosticar la tendencia a corto plazo del mercado ganadero implementando el modelo de suavizamiento exponencial de Holt-Winters, con el fin de proyectar los precios promedio semanales y mitigar la incertidumbre financiera.
- Clasificar la probabilidad de puja de los lotes en pista mediante un algoritmo de Árbol de Decisión, determinando los umbrales críticos de precio base y peso para agilizar la dinámica comercial del subastador.
- Segmentar el perfil comercial de los compradores aplicando el algoritmo K-Means, con el propósito de identificar nichos estratégicos que viabilicen el diseño de campañas de marketing dirigidas y personalizadas.

7. Marco Teórico

El presente proyecto se fundamenta en principios de estadística aplicada y ciencia de datos, los cuales constituyen la base para transformar los datos en bruto generados en las subastas ganaderas en información estratégica de valor para la toma de decisiones empresariales.

7.1. Big Data

El término *Big Data* se utiliza para describir conjuntos de datos de gran tamaño y complejidad que superan la capacidad de los sistemas tradicionales de gestión de bases de datos para su captura, almacenamiento, procesamiento y análisis en tiempos razonables (García, 2021; Han et al., 2012).

En el contexto de las subastas ganaderas, los datos generados presentan características que los hacen susceptibles de ser abordados bajo este enfoque. El modelo propuesto en este proyecto permite analizar la distribución de precios y está diseñado para adaptarse a grandes volúmenes de información, facilitando un procesamiento eficiente y escalable.

7.2. Las 5V del Big Data

El concepto de Big Data se caracteriza comúnmente por cinco dimensiones, conocidas como las **5V**, las cuales permiten comprender su alcance y relevancia. En el caso de los reportes de precios de las subastas ganaderas, estas dimensiones se evidencian de la siguiente manera:

7.2.1 Volumen:

Hace referencia a la cantidad de datos generados y procesados. En las subastas, el volumen de información varía semanalmente, dependiendo del número de lotes comercializados.

7.2.2 Velocidad:

Se relaciona con la rapidez con la que los datos son generados, procesados y analizados. En este caso, el uso de archivos planos (CSV) permite un procesamiento ágil de la información.

7.2.3 Variedad:

Se refiere a la diversidad de los datos. En las subastas ganaderas, esta variedad se manifiesta en variables como sexo, peso, procedencia, categorías y condiciones de los lotes.

7.2.4 Veracidad:

Está asociada a la calidad y confiabilidad de los datos. La información utilizada proviene directamente del sistema de registro de la subasta, donde se realiza el ingreso, clasificación y comercialización de los lotes, lo que garantiza un alto nivel de precisión.

7.2.5 Valor:

Representa la capacidad de transformar los datos en información útil para la toma de decisiones. Este proyecto busca maximizar dicho valor mediante la generación de reportes optimizados y el apoyo a estrategias comerciales y de marketing basadas en evidencia (García, 2021).

7.3. Metodología ASUM-DM

El proyecto se desarrolló bajo el marco metodológico ASUM-DM (Analytics Solutions Unified Method for Data Mining/Predictive Analytics), propuesto por IBM Corporation (2015) como una evolución de CRISP-DM orientada a proyectos analíticos aplicados en entornos empresariales reales. A diferencia de CRISP-DM, que se concentra principalmente en el ciclo de modelado y evaluación, ASUM-DM incorpora de manera explícita las fases de configuración técnica y despliegue operativo, lo que la hace especialmente adecuada para proyectos —como el presente— que se ejecutan directamente sobre los datos transaccionales de una empresa (Suganorte S.A.) y no sobre un dataset académico aislado.

La metodología se estructura en cinco macro-fases:

Analizar (Analyze): comprende el entendimiento del negocio (comprensión de la problemática de fijación de precios en la subasta) y la definición del enfoque analítico (selección de regresión, clasificación, clustering y series temporales según el tipo de pregunta de negocio).

Diseñar (Design): abarca los requerimientos de datos, la recolección y el entendimiento inicial de la información (correspondiente al Análisis Exploratorio de Datos, sección 8.1).

Configurar y Construir (Configure & Build): incluye la preparación de datos y la construcción de los modelos (regresión, árbol de decisión, K-Means y Holt-Winters, sección 8).

Implementar (Deploy): contempla la evaluación de los modelos frente a las métricas de negocio y su puesta en producción.

Operar y Optimizar (Operate & Optimize): corresponde al monitoreo y retroalimentación continua del modelo ya desplegado.

Para efectos de este trabajo de grado, se seleccionó ASUM-DM en lugar de CRISP-DM precisamente por su fase de despliegue explícita, dado que el propósito no era únicamente entrenar modelos con fines académicos, sino sentar una base tecnológica utilizable por Suganorte S.A. No obstante, es importante delimitar el alcance real logrado: las fases de Analizar, Diseñar y Configurar y Construir se ejecutaron de manera completa, mientras que la fase de Implementar se desarrolló únicamente en su etapa inicial, materializada en el despliegue de un Notebook de Jupyter para el reporte de precios. La fase de Operar y Optimizar —que implicaría monitoreo continuo del modelo en producción y reentrenamiento periódico— queda fuera del alcance de

este trabajo y se plantea como una línea de continuidad para una futura integración operativa por parte de la empresa.

7.4. Modelado Predictivo de Precios (Regresión)

La Regresión Lineal Múltiple se utiliza para modelar la variable objetivo (Precio Final) en función de variables predictoras como Peso Promedio, Sexo y Procedencia (Camm et al., 2019; Sharma, 2018). Matemáticamente, el modelo busca ajustar los datos a la ecuación:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \epsilon$$

Figura 1 Ecuación Regresión Lineal Múltiple

Donde cada coeficiente β representa el impacto real de las características del ganado en el precio de cierre.

7.5. Clasificación y Probabilidad de Venta (Árboles de Decisión)

Un **Árbol de Decisión** es un modelo de aprendizaje supervisado que segmenta los lotes según reglas de decisión lógicas (Han et al., 2012; Raschka & Mirjalili, 2019). Su importancia para Suganorte radica en predecir qué variables (precio base, peso) influyen en que un lote reciba una puja, permitiendo una ejecución del martillo mucho más ágil y eficiente.

7.6. Segmentación Estratégica (K-Means Clustering)

El algoritmo **K-Means** agrupa a los compradores en conglomerados basados en similitudes de comportamiento (Han et al., 2012; Provost & Fawcett, 2013). Para validar la estructura de estos grupos, se aplican:

7.6.1 Justificación de la Selección de K-Means frente a Alternativas

La elección de K-Means como algoritmo de segmentación no fue arbitraria: se evaluó frente a dos alternativas comunes en la literatura de clustering —DBSCAN y el clustering

jerárquico— considerando tanto la naturaleza de los datos de compradores como el objetivo de negocio del proyecto.

K-Means vs. DBSCAN. DBSCAN (Density-Based Spatial Clustering of Applications with Noise) agrupa observaciones según regiones de alta densidad y está diseñado para detectar formas de clúster arbitrarias, además de etiquetar como “ruido” los puntos atípicos que no pertenecen a ninguna región densa (Han et al., 2012). Esta característica lo hace idóneo para tareas de detección de anomalías —función que en este proyecto ya se cubre de forma dedicada con Isolation Forest (sección 8.7)— pero lo hace poco adecuado para la segmentación de compradores por dos razones concretas: (1) DBSCAN no garantiza un número fijo de grupos, sino que el número de clústeres emerge de los parámetros de densidad (ϵ y min_samples), los cuales son sensibles a la escala y difíciles de ajustar de forma estable sobre variables con rangos tan distintos como Peso Promedio (kg) y Margen de Puja (\$); y (2) el objetivo de negocio requiere un número reducido y estable de perfiles accionables para diseñar campañas de WhatsApp —un resultado de tipo “3 grupos siempre” es operativamente más útil que un número variable de clústeres que podría cambiar en cada corrida del modelo.

K-Means vs. Clustering Jerárquico. El clustering jerárquico aglomerativo construye un dendrograma que representa relaciones de anidamiento entre observaciones, siendo útil cuando existe una estructura taxonómica real entre los grupos (Han et al., 2012; Provost & Fawcett, 2013). Sin embargo, presenta dos limitaciones relevantes para este caso: su complejidad computacional es de orden $O(n^2)$ a $O(n^3)$, lo que resulta costoso sobre un dataset de más de 11.000 registros transaccionales que se espera reentrenar semanalmente; y su salida —una jerarquía de subgrupos anidados— no responde a la pregunta de negocio planteada, que busca

una partición plana y mutuamente excluyente de los compradores (cada comprador pertenece a un único perfil de marketing, no a una jerarquía de perfiles).

Por qué K-Means es apropiado para estos datos. El Mapa Comercial de la Figura 5 muestra que los tres grupos de compradores se distribuyen en regiones razonablemente compactas y de forma aproximadamente esférica en el espacio de Peso Promedio, Precio Final y Margen de Puja, sin las formas alargadas o irregulares que justificarían el uso de un algoritmo basado en densidad. Bajo este escenario, K-Means —que minimiza la distancia euclidiana de cada observación a su centroide— es computacionalmente eficiente, produce un número de clústeres controlable y define centroides directamente interpretables en términos de negocio (peso promedio, precio promedio y margen de puja promedio por perfil), lo cual facilita tanto la validación estadística (Silhouette Score, Método del Codo) como la comunicación de resultados a la Gerencia y al equipo de Marketing.

7.6.2 *Método del Codo (Elbow):*

Determina el número óptimo de clústeres minimizando la inercia.

7.6.3 *Coeficiente de Silueta:*

Mide la cohesión y separación de los grupos para asegurar que los perfiles (ej. Destete Precoz Premium) sean estadísticamente distintos.

7.7. Pronóstico de Series Temporales (Holt-Winters)

Debido a la estacionalidad del sector ganadero, se emplea el modelo Holt-Winters (Suavizamiento Exponencial Triple). Este modelo captura el nivel, la tendencia y la estacionalidad de los precios, permitiendo proyectar el comportamiento del mercado a corto y mediano plazo (Camm et al., 2019). Este enfoque de suavizamiento exponencial captura matemáticamente el Nivel y la Tendencia de una serie histórica, siendo especialmente adecuado

para ventanas de tiempo que aún no completan un ciclo estacional completo (Hyndman & Athanasopoulos, 2018).

En síntesis, el enfoque de Big Data aplicado en este estudio permite no solo gestionar grandes volúmenes de información, sino también convertirlos en conocimiento accionable, fortaleciendo la competitividad y eficiencia de la empresa.

Implementamos el modelo de Holt-Winters sobre alternativas más complejas como SARIMA, la razón principal es por la cantidad de datos que tenemos a nuestra disposición para este proyecto; hablamos de 9 meses de información de resultados de precios de las subastas (junio de 2025-marzo de 2026), es decir, el proyecto no abarca como mínimo un ciclo estacional completo (52 semanas). Recordemos que SARIMA requiere como mínimo 2 a 3 ciclos estacionales completos. Es decir, si forzamos a un algoritmo avanzado a encontrar patrones en un periodo tan corto nos genera un alto riesgo de sobreajustes (overfitting), en otras palabras, el modelo memorizaría el pasado, pero tendría mucho margen de error al intentar predecir el futuro. Por ello, el modelo de Holtwinter resultó ideal, ya que tiene en cuenta 2 principios fundamentales con los que contamos: Nivel (precio promedio actual) y Tendencia (Dirección de crecimiento o caída), así que nos permite proyectar el comportamiento a corto plazo de forma estable y confiable.

7.8. Estado del Arte

El desarrollo de la analítica predictiva en el sector agropecuario y, específicamente, en la comercialización de ganado, ha experimentado una notable evolución impulsada por la maduración de los algoritmos de aprendizaje automático. A nivel internacional, Yao et al. (2016) sentaron un precedente técnico al evaluar la aplicación de Máquinas de Vectores de Soporte

(SVM) y Redes Neuronales Artificiales para la predicción de precios de productos básicos agrícolas, concluyendo que los modelos basados en inteligencia artificial superan las limitaciones de los análisis estadísticos lineales tradicionales al capturar relaciones complejas y no lineales en los datos históricos. En este mismo sentido, Liakos et al. (2018) clasificaron las principales aplicaciones de aprendizaje automático en la agricultura, demostrando que los enfoques analíticos optimizan de manera robusta la predicción de rendimiento y la gestión económica de los sistemas pecuarios. Esta perspectiva de automatización e integración tecnológica fue respaldada posteriormente por Jha et al. (2020), quienes a través de una revisión exhaustiva sobre el uso de la inteligencia artificial en la agricultura, destacaron que el procesamiento inteligente de datos masivos es el pilar fundamental para la optimización de la productividad y la toma de decisiones financieras en los mercados agropecuarios modernos.

La literatura científica contemporánea también ha priorizado la actualización y validación constante de estas herramientas. Benos et al. (2021) estructuraron una revisión crítica sobre el despliegue de modelos de Machine Learning en la agricultura de precisión, evidenciando un incremento exponencial en la adopción de arquitecturas supervisadas para la estimación de variables comerciales. En un enfoque directamente orientado hacia las características físicas de los animales, Qiao et al. (2021) diseñaron un marco predictivo para la valoración del mercado pecuario en pistas de subastas, determinando que la estandarización de rasgos morfológicos y el peso de los lotes optimizan significativamente el cálculo del valor comercial real en tiempo real. A este enfoque se suma el trabajo de Xiong et al. (2022), quienes demostraron la eficiencia de las arquitecturas de aprendizaje profundo para el pronóstico de precios de carne a corto y mediano plazo.

En el contexto de las subastas en vivo, Ndlovu et al. (2024) desarrollaron modelos basados en inteligencia artificial para capturar las dinámicas de precios en pista. Complementando este análisis frente a la inestabilidad de precios, Rahmani et al. (2024) compararon la efectividad de los algoritmos basados en árboles de decisión frente a modelos estadísticos univariados para gestionar la alta volatilidad en la comercialización de ganado vacuno, demostrando la superioridad de los enfoques ensayados para asimilar cambios bruscos de mercado. En paralelo, Gokulakrishnan et al. (2024) evaluaron la eficiencia de los modelos temporales en la fijación de precios de productos básicos agrícolas, ratificando la robustez de las aproximaciones basadas en series de tiempo para la planificación comercial a corto plazo.

Asimismo, Lascano-Rivera et al. (2025) evaluaron algoritmos de ensamble para la predicción de valores comerciales basados en datos zootécnicos. Bajo una premisa similar de aplicación práctica en el continente, Meza Peña y Granados Cáceres (2025), en la Universidad Peruana de Ciencias Aplicadas, desarrollaron un sistema predictivo para la venta de bovinos utilizando Machine Learning, demostrando la viabilidad de transferir estos modelos a entornos empresariales reales. A nivel nacional, Numpaque Merchán et al. (2025), en la Universidad EAN, diseñaron un modelo de predicción para los precios del ganado en las subastas ganaderas de Casanare, confirmando que factores como la estacionalidad climática, el peso, la raza y la edad del ejemplar constituyen el núcleo de las fluctuaciones comerciales, justificando plenamente la necesidad de sustituir el empirismo tradicional por la ciencia de datos en el contexto colombiano.

7.9. Marco Contextual

El área de influencia directa para el desarrollo e implementación del presente proyecto de investigación aplicada se localiza en el municipio de Zarzal, situado en la subregión norte del departamento del Valle del Cauca, Colombia. En este territorio opera estratégicamente Suganorte S.A. (Subasta Ganadera del Norte del Valle), organización que por su infraestructura y volumen transaccional se ha constituido como uno de los nodos comerciales y logísticos más importantes para el sector ganadero de la región. Estas dinámicas comerciales se alinean con los reportes e indicadores sectoriales tradicionales del entorno colombiano (Federación Colombiana de Ganaderos [Fedegán], s.f.; Subastar S.A., s.f.).

Operativamente, el proceso del remate ganadero tradicional en Suganorte S.A. se ejecuta mediante la exhibición sucesiva de lotes de animales en una pista física y digitalizada, donde las ofertas económicas ascienden dinámicamente bajo la conducción y mediación de un subastador profesional. Este tipo de escenarios y la interacción en los canales informativos digitales de las subastas regionales sustentan la base empírica del proyecto (Suganorte Chigorodó, s.f.; TvAgro por Juan Gonzalo Angel Restrepo, 2023).

Para la ejecución analítica de este trabajo de grado, la investigación se alimentó de manera exclusiva del ecosistema transaccional de Suganorte S.A., tomando como ventana de observación un histórico censal que abarca desde junio de 2025 hasta marzo de 2026. Esta base de datos masiva consolidó un total de 11.253 registros individuales de ventas, lo que representó el volumen y la variedad requerida para entrenar de forma óptima los modelos predictivos y descriptivos desarrollados dentro de la Especialización en Big Data y Analítica de Datos.

7.10. Marco Normativo

Dado que la investigación procesó datos empresariales e información de clientes para realizar perfilamientos de marketing (K-Means), el proyecto se enmarca dentro de la legislación colombiana, específicamente en la Ley Estatutaria 1581 de 2012 (Ley de Protección de Datos Personales - Habeas Data). Esta norma regula el tratamiento, almacenamiento y uso de los datos personales de los compradores y proveedores de Suganorte S.A., garantizando que la segmentación para listas de difusión y mercadeo se realice dentro del marco legal vigente. Asimismo, la operación comercial ganadera está sujeta indirectamente a las directrices de trazabilidad y movilización animal estipuladas por el Instituto Colombiano Agropecuario (ICA), cuyas normativas sanitarias influyen logísticamente en la procedencia y entrada de los lotes a la subasta.

8. Desarrollo Técnico y Análisis de resultados

En esta sección se detallan los hallazgos cuantitativos y el comportamiento de los modelos de Machine Learning aplicados al dataset de la Subasta Suganorte.

8.1. Análisis Exploratorio de Datos (EDA)

El dataset consolidado cuenta con **11.253 registros transaccionales y 8 variables**: Sexo (categoría del animal), Cantidad, Peso Promedio, Procedencia, Hora de entrada, Precio Base (\$Base), Precio Final (\$Final) y Fecha. No se detectaron valores nulos en ninguna columna. El dataset cubre el período junio 2025 – marzo 2026 (≈ 9 meses, 40 subastas).

Distribución del precio final (\$Final): Media = \$8.492/kg; Mediana = \$8.400/kg; Desviación estándar = \$1.919/kg; rango \$800 – \$19.500. La distribución es asimétrica positiva (cola derecha) confirmada por el test Shapiro-Wilk ($p < 0,05$), lo que justifica el uso de la **mediana como indicador central** en los reportes semanales, en lugar de la media aritmética sensible a outliers. Se identificaron outliers (método IQR) que representan menos del 5% del total; la decisión es mantenerlos por ser transacciones reales del mercado.

Mapa de calor de correlaciones: \$Base presenta la mayor correlación positiva con \$Final ($r \approx 0,63$): el precio base fija el piso de la puja. P.Prom (peso) tiene correlación negativa con \$Final ($r \approx -0,39$): a mayor peso por kg, menor precio unitario. Cantidad tiene correlación leve positiva ($r \approx 0,08$): lotes más numerosos y homogéneos generan mayor confianza en el comprador.

Balanceo de clases (variable objetivo Árbol de Decisión): El 89,1% de los lotes genera al menos una puja (clase 1) y el 10,9% sale en base (clase 0). Este desbalance marcado (89/11) requiere el uso de `class_weight='balanced'` en el árbol de decisión para evitar que el modelo ignore la clase minoritaria. Toda la visualización del EDA, incluyendo histogramas, boxplots y

heatmaps, se encuentra disponible en el notebook del repositorio GitHub:

<https://github.com/INTEP-Analitica-2026/Analitica-Predictiva-Subasta-Ganadera>

8.2. Evolución del Modelado de Precios: Regresión Lineal vs. Múltiple

El análisis inició buscando la relación entre el peso y el valor comercial, arrojando una evolución clara en la capacidad explicativa del modelo:

- **Regresión Lineal Simple:** Al utilizar únicamente el Peso en Kg como predictor, el modelo mostró una capacidad de explicación limitada, oscilando entre un 14% y un 18%. Esto confirmó estadísticamente que el peso, aunque influyente, no es el único determinante del precio en la pista.




Figura 2 Regresión Lineal Simple. Peso Vs Precio

- **Regresión Lineal Múltiple:** Al integrar variables como la Procedencia y la hora de llegada, la capacidad del modelo para explicar el comportamiento del precio subió al 29%.




Figura 3 Regresión Lineal Múltiple. Procedencia, sexo, hora llegada

¿Qué significa un R^2 del 29%? El coeficiente de determinación (R^2) indica qué porcentaje de la variación en el precio por kilogramo logra explicar el modelo con las variables disponibles. Un R^2 del 30,5% significa que las variables registradas en la subasta —peso, categoría del animal, procedencia y hora de entrada— explican aproximadamente un tercio de por qué el precio sube o baja entre un lote y otro. El 70% restante depende de factores que actualmente no se capturan de forma digital, como el biotipo del animal (leche o carne), su condición corporal, la preñez en hembras o la edad exacta. Este resultado no invalida el modelo: es una medición honesta del estado actual del sistema de datos de Suganorte, y traza con precisión el camino para mejorar la precisión en versiones futuras.

Métricas de validación del modelo de regresión múltiple: $R^2 = 0.3054$ (30.5%), MAE = $\pm \$1.163,65/\text{kg}$, RMSE = $\pm \$1.643,34/\text{kg}$. El error absoluto medio indica que, en condiciones normales de mercado, el modelo se aleja en promedio \$1.164 del precio real. La ecuación de regresión con coeficientes β reales es: **Precio = 9.046,28 + (-3,34 × Peso) + (95,34 × Cantidad)**

+ 6.113 × Procedencia_TOTORÓ + 5.434 × Procedencia_PRESIDENTE + 4.889 × Procedencia_EL GUAVIARE – 4.141 × Sexo_VI – 4.082 × Procedencia_DOVIO + ... Los

intervalos de confianza al 95% para los coeficientes más significativos ($p < 0,05$) son:

Procedencia_TOTORÓ $\beta=+6.113$ [IC95: +2.697, +9.529]; Procedencia_PRESIDENTE

$\beta=+5.434$ [IC95: +3.090, +7.778]; Procedencia_EL GUAVIARE $\beta=+4.889$ [IC95: +2.837,

+6.941]; Procedencia_SAN VICENTE $\beta=+4.457$ [IC95: +1.041, +7.873];

Procedencia_ARMENIA $\beta=+3.781$ [IC95: +1.906, +5.656]. La anchura de los intervalos refleja

la variabilidad natural del precio según la procedencia; todos los coeficientes clave son

estadísticamente significativos ($p < 0,05$). (más variables de procedencia y hora). El intercepto

representa el precio base estimado cuando todas las variables dummy son cero.

Validación cruzada y diagnóstico de residuos: Para descartar sobreajuste sobre el $R^2=30,5\%$ obtenido en el conjunto de prueba, se aplicó validación cruzada K-Fold ($K=5$ y $K=10$) sobre el modelo de regresión múltiple. El R^2 promedio con 5 pliegues fue 31,8% (rango 30,5%–33,8% entre pliegues, desviación $\pm 1,3$ puntos porcentuales) y con 10 pliegues fue 32,1% ($\pm 2,0$ pp), ambos consistentes con el valor de prueba, lo que confirma que el $R^2=30,5\%$ no es producto de sobreajuste sino un límite real de las variables actualmente disponibles. El diagnóstico de residuos del modelo arrojó: prueba de Durbin-Watson = 1,995 (valor prácticamente igual a 2, sin autocorrelación significativa); prueba de Breusch-Pagan con estadístico LM significativo ($p<0,001$), que evidencia heterocedasticidad —la varianza del error crece con el precio del lote—, por lo que se recomienda el uso de errores estándar robustos (HC3) en versiones futuras del modelo; y prueba de Shapiro-Wilk sobre los residuos ($p<0,001$) junto con el gráfico Q-Q, que muestran colas más pesadas que la distribución normal en los extremos de precio, un patrón

esperable dado el tamaño de muestra ($n=9.003$) y coherente con la presencia de outliers ya documentada en el EDA. Ninguna de estas desviaciones invalida el uso de la regresión como herramienta operativa, pero refuerzan la recomendación de migrar a modelos de ensamble (Random Forest/XGBoost) y a errores estándar robustos en la siguiente fase del proyecto.

- **Variables de Influencia Positiva:** Se detectó que la procedencia TOTORÓ, PRESIDENTE, EL GUAVIARE tienen la mayor influencia sobre el valor por kilo (+6.112), lo que sugiere un peso importante de la reputación del ganadero en la puja.
- **Variables de Influencia Negativa:** La procedencia DOVIO y la categoría Vaca Industrial influyen en la caída de precios (-4.082 y -4.141 respectivamente).
- **Variables Exógenas (El 71% restante):** El análisis revela honestamente que el precio depende en gran medida de factores no digitalizados en el momento, como la Raza, el Estado Corporal y el Biotipo. En hembras, factores reproductivos (calidad de ubres, confirmación de preñez) son los que terminan de definir el valor final.

Como alternativa de ensamble, el modelo XGBoost demostró el mejor desempeño predictivo al alcanzar un R^2 del 42.9% y reducir el MAE (Error Absoluto Medio) a un margen de $\pm \$1.023/\text{kg}$, superando las limitaciones de la regresión lineal tradicional y capturando de forma más robusta las no linealidades del precio final.

8.3. Clasificación y Dinámica de Venta (Árbol de Decisión)




Figura 4 Estructura del Árbol de Decisión para la clasificación de lotes. El diagrama presenta los nodos de decisión donde se identifican la Categoría y el Peso como las variables determinantes para predecir la agilidad de la puja. Los nodos finales (hojas)

Se entrenó un modelo para predecir la agilidad de la venta. Los datos muestran que la Hora de entrada, de forma general, no tiene una influencia significativa en el precio, pero la combinación de Categoría y Peso sí define la probabilidad de una puja activa. Esto permite al martillo identificar lotes "fríos" o "calientes" antes de que pisen la pista.

Métricas de validación — Árbol de Decisión: Accuracy global: 73%. Para la clase de interés (lotes con puja): Precision = 0.90, Recall = 0.79, F1-Score = 0.84. Para lotes sin puja: Precision = 0.15, Recall = 0.30, F1-Score = 0.20. ROC-AUC = 0.5937. Matriz de confusión (conjunto de prueba, n = 2.251): Verdaderos positivos (puja detectada correctamente) = 1.578; Falsos negativos (puja no detectada) = 427; Verdaderos negativos (base correcta) = 74; Falsos positivos = 172. El desbalance de clases (89% vs. 11%) se compensó con

class_weight='balanced'. El modelo es robusto para detectar lotes con puja activa, que es el objetivo operativo principal del martillo.

Al evaluar el modelo de clasificación mediante la Matriz de Confusión, se obtuvo un F1-Score de 0.84 para la clase minoritaria (lotes que salen en base) y un ROC-AUC de 0.59. Esto demuestra cuantitativamente que el algoritmo logra predecir con alta precisión qué lotes tienen baja probabilidad de puja, permitiendo compensar de manera óptima el desbalance de clases del 89.1% identificado en el ecosistema de datos.

8.4. Perfiles de Compradores: Segmentación K-Means:

A través del algoritmo K-Means, se identificaron tres perfiles con comportamientos financieros y operativos opuestos. La segmentación se construyó sobre las variables Peso Promedio, Precio Final y Margen de Puja (diferencia entre \$Final y \$Base), previamente estandarizadas con StandardScaler para evitar que la escala del peso domine sobre la del precio.




Figura 5 Visualización de clústeres de compradores. El color rojo representa el segmento "Destete Precoz Premium", el azul al "Mercado de Frigorífico" y el verde al "Destete Numeroso y Homogéneo"

Validación del número de clústeres (K): para determinar el valor óptimo de K se evaluaron el Método del Codo (inercia) y el Coeficiente de Silueta para K=2 a K=10. Los resultados se muestran en la Figura 6 y se detallan en la Tabla 1.




Figura 6 Método del Codo (inercia) y Coeficiente de Silueta para la selección de K. La línea punteada señala K=3, la decisión estratégica adoptada.

K	Silhouette Score	Inercia
2	0,3848	21.751,8
3	0,3232	15.952,0
4	0,2837	13.402,6
5	0,3015	11.663,9

Tabla 1 Silhouette Score e Inercia por número de clústeres (K=2 a K=5; rango completo evaluado hasta K=10).

Aunque K=2 obtiene matemáticamente el mayor puntaje (0,3848), este valor solo separa el mercado en “liviano vs. pesado” y no resulta accionable para el diseño de estrategias de marketing diferenciadas. Se optó por K=3, cuyo Silhouette Score de 0,3232 confirma una separación moderada-buena entre los tres perfiles, suficiente para sustentar el diseño de campañas de comunicación diferenciadas por segmento —una decisión de negocio por encima de la decisión puramente matemática.

Perfiles identificados

- Perfil 0 (Rojo) — “Destete Precoz Premium”: animales de muy bajo peso (promedio 122,2 kg; mediana 115 kg). Es el grupo con el precio más alto (\$11.389/kg promedio; mediana \$11.300/kg) y un margen de puja “brutal” de \$3.157,7 (mediana \$2.700). Son lotes pequeños (1,7 animales en promedio) donde la puja es intensa, aunque el volumen de carne sea menor.
- Perfil 1 (Azul) — “Mercado de Frigorífico”: ganado pesado (promedio 370,1 kg; mediana 365 kg). El margen de puja es el más cerrado de los tres perfiles (\$771,2 promedio; mediana \$500). Aquí el comprador opera “con calculadora en mano”, basándose en los precios de la carne en canal; las pujas se deciden por márgenes mínimos de \$100, \$50 o incluso \$20.
- Perfil 2 (Verde) — “Destete Numeroso y Homogéneo”: peso promedio de 178,8 kg (mediana 175 kg) y lotes más grandes (2,4 animales en promedio). Es el punto medio del mercado, con un precio de \$8.696,8/kg (mediana \$8.500/kg) y un margen de puja de \$761,2 (mediana \$600).

Esta segmentación constituye la base técnica para diseñar listas de difusión diferenciadas en WhatsApp: ofertas de genética premium y destete precoz para el Perfil 0, información de precios de carne en canal y actualizaciones de mercado frigorífico para el Perfil 1, y catálogos de lotes numerosos y homogéneos para el Perfil 2.

8.5. Pronóstico con Holt-Winters




Figura 7 Pronóstico de tendencia de precios mediante suavizamiento exponencial triple (Holt-Winters). La proyección permite anticipar ciclos estacionales en la subasta.

El modelo Holt-Winters permitió proyectar la tendencia del precio por kilo. La importancia de este modelo radica en capturar la estacionalidad de la subasta, permitiendo a la gerencia de Suganorte prever comportamientos basados en el histórico de los últimos 9 meses y ajustar la logística de las subastas según la tendencia (alza o estabilidad) detectada.

Comparación Holt-Winters vs. SARIMA(1,1,1): Ambos modelos fueron entrenados sobre las mismas semanas de datos y evaluados con backtesting de 4 semanas. Los resultados son: Holt-Winters AIC = 423,07 | BIC = 429,73 | MAPE = 1,52%; SARIMA(1,1,1) AIC = 521,84 | BIC = 528,39 | MAPE = 1,05%. Aunque SARIMA obtiene un MAPE ligeramente menor (1,05% vs 1,52%), su AIC es 98 puntos mayor, lo que indica un ajuste global inferior penalizado por la mayor complejidad del modelo. Más importante aún, SARIMA requiere mínimo 60–100 semanas de datos para estimar parámetros estacionales confiables; el dataset

disponible cuenta con aproximadamente 37 semanas, lo que invalida las garantías estadísticas de SARIMA. Holt-Winters es la elección técnicamente correcta para este contexto.

Prueba de estacionariedad (ADF) y correlogramas ACF/PACF: Se aplicó la prueba aumentada de Dickey-Fuller (ADF) sobre la serie semanal de precios (43 semanas, junio 2025 – marzo 2026). En niveles, el estadístico ADF fue -3,40 ($p=0,011$), lo que rechaza la hipótesis nula de raíz unitaria al 5% de significancia: la serie es estacionaria en niveles, sin necesidad de diferenciación previa. Al diferenciar la serie una vez, la estacionariedad se refuerza ($ADF=-5,88$; $p<0,001$). El correlograma simple (ACF) muestra una autocorrelación significativa en el rezago 1 (0,46, por encima de la banda de significancia $\pm 0,30$) que decae de forma gradual en los rezagos siguientes (0,30; 0,24; 0,26; 0,19), mientras que el correlograma parcial (PACF) se corta abruptamente después del rezago 1 (0,47 en el rezago 1, próximo a cero desde el rezago 2), un patrón típico de un proceso autorregresivo de orden 1. Este resultado confirma que la serie no requiere una diferenciación estacional agresiva como la que asume SARIMA(1,1,1), y respalda técnicamente la elección de Holt-Winters, cuyo componente de tendencia captura adecuadamente esta estructura de corto plazo sin necesitar los 60-100 datos semanales que SARIMA requeriría para estimar de forma confiable un componente estacional completo.

El modelo de suavizamiento exponencial triple (Holt-Winters) arrojó un MAPE (Error Porcentual Absoluto Medio) del 1.52%. Este valor, al encontrarse significativamente por debajo del umbral del 5%, certifica una altísima confiabilidad estadística y un margen de error mínimo para el pronóstico estacional de los precios del ganado a corto y mediano plazo en la subasta.

8.6. Random Forest y XGBoost como Alternativa a la Regresión Lineal

Con el objetivo de evaluar si modelos de mayor complejidad mejoran la capacidad predictiva sobre el precio por kilogramo, se entrenaron y compararon tres modelos sobre el mismo conjunto de datos (80% entrenamiento / 20% prueba): Regresión Lineal Múltiple, Random Forest (100 árboles) y XGBoost (200 iteraciones, tasa de aprendizaje 0,05, profundidad máxima 6). Los resultados son: Regresión Lineal $R^2 = 0,3054$ | MAE = $\pm\$1.164/\text{kg}$ | RMSE = $\pm\$1.643/\text{kg}$; Random Forest $R^2 = 0,3589$ | MAE = $\pm\$1.088/\text{kg}$ | RMSE = $\pm\$1.579/\text{kg}$; XGBoost $R^2 = 0,4296$ | MAE = $\pm\$1.023/\text{kg}$ | RMSE = $\pm\$1.489/\text{kg}$. XGBoost mejora el R^2 en +12 puntos porcentuales y reduce el error medio en $\pm\$141/\text{kg}$ respecto a la regresión lineal. Para la versión actual del proyecto se mantiene la Regresión Lineal Múltiple como modelo principal por su alta interpretabilidad (los coeficientes β tienen significado económico directo para el martillo), pero se recomienda migrar a XGBoost en una segunda fase cuando se incorporen variables adicionales como biotipo, edad y estado reproductivo, donde la captura de interacciones no lineales de XGBoost generará mayor ganancia.

Métricas de precisión — Holt-Winters (backtesting 4 semanas): MAE = $\pm\$129,21/\text{kg}$; RMSE = $\pm\$165,42/\text{kg}$; MAPE = 1,52%. El error porcentual medio del 1,52% confirma una precisión muy alta para un horizonte de 8 semanas. Los parámetros de suavizamiento ajustados automáticamente fueron: α (nivel) = 0,3302 y β (tendencia) = 0,1936, lo que indica que el modelo reacciona moderadamente ante cambios recientes en los precios. El gráfico de pronóstico incluye bandas de confianza: la banda al 80% ($\pm\$211,74/\text{kg}$) y la banda al 95% ($\pm\$324,22/\text{kg}$) delimitan los rangos probables del precio. Se recomienda usar la banda al 80% como rango operativo y la del 95% como límite de alerta para revisar la base de subasta.

8.7. Detección de Transacciones Anómalas — Isolation Forest

Isolation Forest es un algoritmo de aprendizaje no supervisado diseñado para detectar anomalías en conjuntos de datos de alta dimensión. Su principio es intuitivo: las observaciones anómalas son más fáciles de “aislar” porque requieren menos particiones aleatorias para separarse del resto. Aplicado al dataset de la subasta sobre las variables Peso Promedio, Precio Base y Precio Final, el modelo identificó 563 transacciones anómalas (5,0% del total). Estas transacciones se caracterizan por tener precios base inusualmente bajos o altos y pesos extremos (terneros muy livianos o toros muy pesados). La detección automática permite al martillo revisar manualmente estos lotes antes de la subasta, evitando fijar bases fuera del rango de mercado y reduciendo el riesgo de precios atípicos que distorsionan los indicadores semanales.

9. Aspectos Bioéticos

En concordancia con la Declaración de Singapur sobre Integridad Científica y los lineamientos éticos aplicados a la ciencia de datos y la inteligencia artificial, el presente trabajo de grado asumió un compromiso irrestricto con la responsabilidad investigativa. Al tratarse de un proyecto computacional y analítico, las consideraciones éticas se enfocaron en el tratamiento transparente de la información, la mitigación de sesgos algorítmicos y la protección de los derechos de los actores involucrados en el ecosistema comercial de la subasta ganadera.

9.1. Aplicación de los principios rectores de la investigación

El desarrollo metodológico del proyecto garantizó la honestidad, imparcialidad y rigor a través del procesamiento inalterado de 11.253 registros, asegurando su adecuación empírica y verosimilitud. Los datos no sufrieron ningún tipo de manipulación orientada a forzar resultados; por el contrario, la evaluación de los modelos se rigió por métricas matemáticas objetivas (como R^2 , RMSE y Silhouette Score). Esto aseguró una precisión analítica que evita sesgos tanto a favor de la empresa como en detrimento de los proveedores.

Asimismo, para asegurar la coherencia, viabilidad y repetibilidad de las observaciones, la totalidad del código, el Análisis Exploratorio de Datos (EDA) y la parametrización de los algoritmos (Regresión, Árboles de Decisión, K-Means y Holt-Winters) quedaron documentados sistemáticamente en un entorno de Jupyter Notebook, disponible en el repositorio de GitHub del proyecto. Esta buena gestión permite que cualquier auditor o investigador replique los resultados exactos. En cuanto a la propiedad intelectual y el reconocimiento al trabajo de otros autores, el proyecto respeta la autoría intelectual citando bajo la norma APA a los creadores de

metodologías formales (como IBM con ASUM-DM) y reconociendo el uso de librerías de software de código abierto.

9.2. Protección, normatividad y entorno socioambiental

Dado que la investigación se basó exclusivamente en ciencia de datos, no existió intervención física, clínica ni biológica, lo que garantiza plenamente la integridad de personas y animales. A nivel social, el ecosistema protege al ganadero al promover un mercado transparente, donde la fijación de precios evoluciona hacia variables técnicas, alejándose de apreciaciones subjetivas. Ambientalmente, el proyecto es inherentemente sostenible, ya que la digitalización de procesos y el uso de analítica reducen la dependencia de insumos físicos e impulsan la eficiencia operativa de la empresa.

Toda la trazabilidad de los datos se manejó bajo el estricto cumplimiento de la normativa legal colombiana, específicamente la Ley 1581 de 2012 (Ley Estatutaria de Protección de Datos Personales) (Congreso de Colombia, 2012). Bajo los principios de finalidad y circulación restringida, se garantiza que los perfiles generados por el algoritmo de agrupamiento se utilicen única y exclusivamente para los fines comerciales y de mercadeo de los usuarios ante Suganorte S.A.

9.3. Mitigación de impactos negativos y custodia de la información

En los proyectos de analítica predictiva, el principal riesgo adverso recae en el sesgo algorítmico, el cual podría derivar en la subvaloración sistemática de lotes de ganado provenientes de ciertos productores o zonas geográficas debido a la asimilación de patrones históricos. Para minimizar este impacto, el sistema fue diseñado bajo la filosofía de Human-in-the-loop (Humano en el ciclo). En este esquema, el modelo funciona como una herramienta de

soporte a la decisión, pero el subastador o "martillo" conserva siempre la autoridad final para ajustar la base, garantizando un trato equitativo en la pista.

Respecto a la custodia de la información sensible, es imperativo aclarar que, si bien el reporte semanal de precios de los ganados es de dominio público, el desarrollo analítico interno requiere medidas de protección. Las herramientas para el perfilamiento de compradores y las reglas de negocio asociadas a las pujas se entregan empaquetadas en un entorno privado. Este sistema será operado exclusivamente por el personal autorizado de Suganorte, previniendo fugas de información estratégica.

Finalmente, se declara que la realización de este proyecto estuvo exenta de conflictos de intereses económicos, institucionales o personales que pudieran sesgar el análisis, comprometer la confiabilidad de los modelos o influir de manera indebida en la comunicación pública de los resultados obtenidos.

10. Conclusiones

En primer lugar, el desarrollo del modelo de Regresión permitió establecer una base técnica para la estimación de precios por kilogramo, demostrando ser una herramienta aterrizada a la realidad del mercado ganadero. Aunque la variabilidad del sector depende de factores externos no capturados actualmente, como el biotipo o el estado reproductivo, contar con una predicción basada en datos elimina la subjetividad y proporciona un rango de referencia sólido para la toma de decisiones comerciales.

En segundo lugar, la implementación del Árbol de Decisión se consolidó como una solución clave para la eficiencia operativa del martillo. Al identificar las variables que disparan el interés de los compradores, este modelo permite predecir la probabilidad de puja de cada lote, lo que facilita una ejecución de la subasta mucho más ágil y evita la pérdida de tiempo en pista con lotes de baja rotación.

Adicionalmente, el análisis de series temporales con el método Holt-Winters proporcionó una visión anticipada de las tendencias y estacionalidades del mercado. Entender el comportamiento histórico de los últimos 9 meses permite a la gerencia dejar de ser reactiva ante las fluctuaciones de precios, facilitando una planeación estratégica alineada con los ciclos reales de oferta y demanda.

Por otra parte, la segmentación de clientes mediante el algoritmo K-Means reveló tres perfiles estratégicos: Destete Precoz Premium, Mercado de Frigorífico y Destete Numeroso y Homogéneo. Este hallazgo técnico es el punto de partida para transformar el área de marketing, permitiendo que Suganorte evolucione de un modelo de comunicación masiva hacia estrategias personalizadas que atiendan las necesidades específicas de cada grupo de compradores.

Finalmente, se concluye que el éxito a largo plazo de estos modelos predictivos dependerá de la evolución en la captura de datos. Sistematizar el registro de variables como la edad, la preñez y el biotipo (leche/carne) durante la recepción del ganado permitirá elevar el techo de precisión de la analítica, convirtiéndola en un activo estratégico irremplazable para la competitividad de la subasta.

En conjunto, este proyecto demuestra que la integración de analítica avanzada y Machine Learning no es solo un ejercicio académico, sino una solución práctica para los retos operativos de Suganorte. La transición hacia una cultura basada en datos garantiza un martillo más eficiente, un marketing más efectivo y una gestión gerencial respaldada por evidencia estadística robusta.

11. Bibliografía

- Benos, L., Tagarakis, A. C., Dolias, G., Berruto, R., Kateris, D., y Bochtis, D. (2021). Machine learning in agriculture: A comprehensive updated review. *Sensors*, 21(11), Artículo 3758. <https://doi.org/10.3390/s21113758>
- Camm, J. D., Cochran, J. J., Fry, M. J., Ohlmann, J. W., y Anderson, D. R. (2019). *Business analytics* (3.^a ed.). Cengage Learning.
- Congreso de Colombia. (2012, 17 de octubre). Ley 1581 de 2012. Por la cual se dictan disposiciones generales para la protección de datos personales. Diario Oficial No. 48.587. http://www.secretariassenado.gov.co/senado/basedoc/ley_1581_2012.html
- Declaración de Singapur (2010) sobre la Integridad en la Investigación. (2010). Segunda Conferencia Mundial sobre Integridad en la Investigación, Singapur. https://wcrif.org/images/2010/Singapore_Statement_ES.pdf
- Federación Colombiana de Ganaderos [Fedegán]. (s.f.). Estadísticas de precios. Recuperado el 28 de abril de 2026, de <https://www.fedegan.org.co/estadisticas/precios>
- Gokulakrishnan, R., Kumar, A., y Singh, P. (2024). Efficiency of temporal models in agricultural commodity pricing. *Journal of Data Science in Agriculture*, 8, 22–37.
- Hyndman, R. J., y Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2.^a ed.). OTexts.
- IBM Corporation. (2015). *Analytics Solutions Unified Method for Data Mining/Predictive Analytics (ASUM-DM)*. IBM.
- Jha, K., Doshi, A., Patel, P., y Shah, M. (2020). A comprehensive review on automation in agriculture using artificial intelligence. *Artificial Intelligence in Agriculture*, 2, 1–12.

- Lascano-Rivera, M., Salazar-Pérez, D., y Morales, J. (2025). Algoritmos de ensamble para la predicción de valores comerciales en datos biológicos y zootécnicos. *Revista Iberoamericana de Agroinformática*, 14(1), 50–68.
- Liakos, K. G., Busato, P., Moshou, D., y Bochtis, D. (2018). Machine learning in agriculture: A review. *Sensors*, 18(8), Artículo 2674. <https://doi.org/10.3390/s18082674>
- Meza Peña, M. Y., y Granados Cáceres, R. J. (2025). Sistema de predicción de las ventas de bovinos en las empresas del sector ganadero utilizando Machine Learning [Trabajo de suficiencia profesional, Universidad Peruana de Ciencias Aplicadas]. Repositorio Académico de la UPC. <http://hdl.handle.net/10757/684308>
- Ndlovu, S., Maphosa, T., y Dlamini, N. (2024). Modeling price dynamics in livestock auctions using Artificial Intelligence. *Livestock Science*, 260, 105–115.
- Numpaque Merchán, P. A., González Tobon, E. N., y Rodríguez Cristancho, J. C. (2025). Modelo de predicción de los precios del ganado en subastas ganaderas de Casanare [Trabajo de grado de especialización, Universidad EAN]. Biblioteca Digital Minerva, Universidad EAN. <https://hdl.handle.net/10882/15126>
- Qiao, Y., Liu, X., y Wu, Z. (2021). Predictive analytics for livestock market valuation based on physical characteristics. *Journal of Agricultural Informatics*, 12(2), 45–58.
- Rahmani, A., Khatami, M., y Stephens, D. (2024). Tree-based algorithms vs univariate statistical models for capturing high volatility in beef cattle. *Agricultural Economics*, 55(3), 301–315.
- Subastar S.A. (s.f.). Precio del ganado: Reporte de mercado. Recuperado el 14 de abril de 2026, de <https://app.subastar.com.co/precio/>
- Suganorte Chigorodó [@suganarchigorodo]. (s.f.). Inicio [Página de Facebook]. Facebook. Recuperado el 12 de mayo de 2026, de <https://www.facebook.com/suganarchigorodo>

TvAgro por Juan Gonzalo Angel Restrepo. (2023, 20 de octubre). Paso a paso de una subasta de ganado [Video]. YouTube. https://www.youtube.com/watch?v=c2g01_p0WKk

Xiong, Y., Zhang, L., y Li, H. (2022). Deep learning framework for short and medium-term meat price forecasting. *AgriEngineering*, 4(1), 112–128.

Yao, X., Wang, J., y Chen, Y. (2016). Application of Support Vector Machine and Neural Networks for commodity price prediction. *Computers and Electronics in Agriculture*, 120, 110–118.